



**T.C.  
NECMETTİN ERBAKAN  
ÜNİVERSİTESİ  
SEYDİŞEHİR AHMET CENGİZ  
MÜHENDİSLİK FAKÜTESİ**



**BİLGİSAYAR MÜHENDİSLİĞİ BÖLÜMÜ**

**DERİN ÖĞRENME İLE GÖRÜNTÜ ÜZERİNDEN CİNSİYET, YAŞ VE  
DUYGU ANALİZİ**

**19370031006 Fadime COŞKUNER  
19370031070 Meryem ŞAHİN**

**Danışman:  
Dr. Öğr. Üyesi Yunus Emre GÖKTEPE**

**BİLGİSAYAR MÜHENDİSLİĞİNDE  
TASARIM I-II TEZİ**

**Mayıs- 2023  
SEYDİŞEHİR  
Her Hakkı Saklıdır**

## LİSANS BİTİRME ÖDEVİ SONUÇ FORMU

Fadime COŞKUNER ve Meryem ŞAHİN tarafından Yunus Emre GÖKTEPE danışmanlığında hazırlanan “Derin Öğrenme ile Görüntü Üzerinden Cinsiyet, Yaş ve Duygu Analizi” başlıklı lisans bitirme ödevi tarafımızdan incelenmiş, kapsamı ve niteliği açısından, ... / ... / 20... tarihinde bir Lisans Bitirme Ödevi olarak kabul edilmiştir / edilmemiştir.

Unvan Ad SOYAD

Danışman

Unvan Ad SOYAD

Jüri Üyesi

Unvan Ad SOYAD

Jüri Üyesi

Unvan Ad SOYAD

Bölüm Başkanı

## **TEZ BİLDİRİMİ**

Bu tezdeki bütün bilgilerin etik davranış ve akademik kurallar çerçevesinde elde edildiğini ve tez yazım kurallarına uygun olarak hazırlanan bu çalışmada bana ait olmayan her türlü ifade ve bilginin kaynağına eksiksiz atıf yapıldığını bildiririm.

## **DECLARATION PAGE**

I hereby declare that all information in this document has been obtained and presented in accordance with academic rules and ethical conduct. I also declare that, as required by these rules and conduct, I have fully cited and referenced all material and results that are not original to this work.

Seydişehir, 23/05/ 2023

Fadime COŞKUNER  
Meryem ŞAHİN

## ÖZET

### DERİN ÖĞRENME İLE GÖRÜNTÜ ÜZERİNDEN CİNSİYET, YAŞ VE DUYGU ANALİZİ

Görüntü işleme teknikleri, bilgisayarların görüntülerdeki nesneleri ve kişileri tanımlamasını ve anlamasını sağlamaktadır. Bu teknikler, yapay zekâ ve derin öğrenme gibi alanlardan gelen girişleri kullanarak insan görsel sistemini taklit etmeye çalışmaktadır. Yaş, cinsiyet ve duygu analizi ise bu tekniklerin bir parçası olarak görüntüler üzerinde gerçekleştirilmektedir.

Analiz sürecinde, görüntülerdeki yüzlerin tespit edilmesi ve bu yüzlerin yaş, cinsiyet ve duygu gibi karakteristik özelliklerinin belirlenmesi hedeflenmektedir. Bu analizler, yüz hatlarının ve ifadelerin incelenmesiyle gerçekleştirilmektedir. Örneğin, yaş analizi için yüzdeki kırışıklıklar ve yaşlanma belirtileri göz önünde bulundurulmaktadır. Cinsiyet analizi için ise yüz hatları ve yüz ifadeleri dikkate alınmaktadır. Duygu analizi ise yüz ifadelerindeki değişiklikler üzerinden gerçekleştirilmektedir. Bu tür analizlerin kullanım alanları oldukça geniştir. Örneğin, pazarlama ve reklamcılık sektöründe hedef kitle analizi için kullanılabilir. Aynı zamanda sağlık sektöründe, hastaların duygusal durumlarını izlemek ve değerlendirmek için kullanılmaktadır. Eğitim alanında ise öğrenci duygusal durumlarını anlamak ve eğitim yöntemlerini buna göre ayarlamak için kullanılabilir.

**Anahtar Kelimeler:** Analiz, Cinsiyet, Derin Öğrenme, Duygu, Yaş, Yapay Zekâ.

## **ABSTRACT**

### **GENDER, AGE AND EMOTION ANALYSIS BY IMAGE WITH DEEP LEARNING**

Image processing techniques enable computers to identify and understand objects and individuals in images. These techniques aim to mimic the human visual system by using inputs from fields such as artificial intelligence and deep learning. Gender, age, and emotion analysis are performed as part of these techniques on images.

During the analysis process, the detection of faces in the images and the determination of characteristics such as age, gender, and emotion of these faces are targeted. These analyses are conducted by examining facial features and expressions. For example, age analysis takes into account wrinkles and signs of aging on the face. Gender analysis, on the other hand, considers facial features and expressions. Emotion analysis is performed by observing changes in facial expressions. These types of analyses have broad applications. For instance, they can be used in marketing and advertising for target audience analysis. They are also used in the healthcare sector to monitor and evaluate patients' emotional states. In the field of education, they can be employed to understand students' emotional states and adjust teaching methods accordingly.

**Keywords:** Analysis, Gender, Deep Learning, Emotion, Age, Artificial Intelligence.

## ÖNSÖZ

Derin öğrenme yöntemlerinin kullanılarak görüntü üzerinden yaş, cinsiyet ve duygu analizi yapmayı amaçlamaktadır. Gelişen derin öğrenme algoritmalarıyla birlikte, bilgisayarın insan benzeri analitik yeteneklerini kullanma potansiyeli ortaya çıkmaktadır.

Büyük bir görüntü veri seti üzerinde eğitilen bir derin öğrenme modeli geliştirilmiştir. Model, gerçek zamanlı olarak yaş, cinsiyet ve duygu tahmini yapabilme yeteneği kazanmıştır. Derin öğrenme algoritmalarının görüntü analizi alanında ne kadar etkili olabileceğini ve yaş, cinsiyet ve duygu analizindeki potansiyelini değerlendirmeyi amaçlamaktadır.

Bu çalışmanın hazırlanması sürecindeki destek sağlayan herkese teşekkür etmek isteriz. Danışanımız Dr. Öğr. Üyesi Yunus Emre GÖKTEPE, rehberlik ve önerileriyle bu araştırmanın kalitesini artırmamıza yardımcı oldu. Ayrıca, önceki çalışmalar ve kaynaklar da bu tezin temelini oluşturmuştur. Yapmış olduğumuz çalışmanın, derin öğrenme yöntemlerinin kullanıldığı bu tür uygulamaların günlük hayattaki potansiyelini göstermek amacıyla önemli bir katkı sunacağına inanıyoruz.

Saygılarımızla.

19370031070 Meryem ŞAHİN  
19370031006 Fadime COŞKUNER  
SEYDİŞEHİR- 2023

## İÇİNDEKİLER

ÖZET .....	iv
ABSTRACT.....	v
ÖNSÖZ .....	vi
İÇİNDEKİLER.....	vii
ŞEKİLLER DİZİNİ.....	viii
ÇİZELGELER DİZİNİ.....	ix
SİMGELER VE KISALTMALAR .....	x
1. GİRİŞ.....	1
2. KAYNAK ARAŞTIRMASI .....	3
3. MATERYAL VE YÖNTEM.....	6
3.1. Materyaller.....	6
3.1.1. Derin Öğrenme .....	6
3.1.2. Görüntü İşleme .....	7
3.1.3. Evrişimli Sinir Ağları (CNN-Convolutional Neural Networks).....	8
3.1.4. Kütüphaneler.....	11
3.1.5. Haar Cascade Sınıflandırıcısı.....	12
3.1.6. Fer2013 Veri Kümesi.....	14
3.1.7. UTK Face Veri Kümesi .....	15
3.2. Yöntem.....	16
4. ARAŞTIRMA SONUÇLARI VE TARTIŞMA.....	20
4.1. Araştırma Sonuçları .....	20
4.1.1. Veri Kümesi ve Özelliklerinin Değerlendirilmesi .....	20
4.1.2. Yaş ve Cinsiyet Tespiti Analiz Sonuçları .....	20
4.1.3. Duygu Tespiti Analiz Sonuçları .....	22
4.1.4. Analiz Sonuçları Ekran Görüntüleri .....	24
4.2. Tartışma .....	26
5. SONUÇLAR VE ÖNERİLER.....	27
5.1. Sonuçlar .....	27
5.2. Öneriler .....	27
6. KAYNAKLAR .....	30
ÖZGEÇMİŞ .....	322

## ŞEKİLLER DİZİNİ

Şekil 1. Makine Öğrenimi ve Derin Öğrenme Mimarisi .....	7
Şekil 2. Evrişim Uygulaması .....	9
Şekil 3. Havuzlama İşlemi .....	9
Şekil 4. Flatten İşlemi .....	9
Şekil 5. Cascade Sınıflandırıcı İşlem Süreci .....	13
Şekil 6. Haar Özellikler ve Uygulamaları (Burun ve Yanak) .....	14
Şekil 7. Haar Özellikler ve Uygulamaları .....	14
Şekil 8. Fer2013 Veri Kümesindeki Sınıflara Ait Örnekler, Örnek Sayısı ve Dağılımı. ....	15
Şekil 9. Akış Diyagramı .....	16
Şekil 10. CNN Akış Diyagramı .....	17
Şekil 11. Ekran Görüntüsü (Şaşırmış) .....	24
Şekil 12. Ekran Görüntüsü (Kızgın) .....	25
Şekil 13. Ekran Görüntüsü (Mutlu) .....	25
Şekil 14. Ekran Görüntüsü (Üzgün) .....	26



## ÇİZELGELER DİZİNİ

Tablo 1. Kullanılan Kütüphaneler .....	12
Tablo 2. Haar Cascade Sınıflandırıcıda Kullanılan Haar Öznitelikleri .....	13
Grafik 1. Yaş ve Cinsiyet Analizi Doğruluk Oranları .....	22
Grafik 2. Duygu Analizi Doğruluk Oranları.....	24

## SİMGELER VE KISALTMALAR

### Kısaltmalar

YSA: Yapay Sinir Ağları (Artificial Neural Network)

CNN: Evrişimli Sinir Ağları (Convolutional Neural Networks)

Fer2013: Yüz İfadesi Tanıma (Facial Expression Recognition)

OpenCV: Açık Kaynaklı Bilgisayar Görü Kütüphanesi (Open Source Computer Vision Library)

2B: İki Boyutlu

## 1. GİRİŞ

İnsanlar sosyal bir varlık olması sebebiyle çevreyle etkileşim halindedir. Yaş, cinsiyet ve duygu sosyal etkileşimlerde önemli bir etkidir. Hitap şeklinin belirlenmesinde kişinin yaş ve cinsiyetinin farklılığına göre hitabetin değişmesi, duygu durumuna göre ise üslubun farklılık göstermesi bu sosyal etkileşimlerden birkaçıdır. Yüz ifadesi gibi psikolojik durumun değerlendirilmesinin, insanlar tarafından bile bazen kolay olmadığı düşünüldüğünde, bilgisayar ile bu işlemin gerçekleşmesinin ne derecede zor olduğu anlaşılmaktadır. (Nabiyev, 2016, s. 745-746) Fakat gelişen teknoloji ve dijital hayat ile birlikte günümüzün önemli çalışma ve araştırma alanlarından birisini görüntü işleme ile yüz analizi çalışmaları oluşturmaktadır.

Görüntü işleme, bilgisayarların görüntüler ve videolardaki nesneleri/kişileri tanımlamasını ve anlamasını sağlamaya odaklanan bir bilgisayar bilimi alanıdır. Görüntü işleme uygulamaları, insanlardaki görme sisteminin işleyişini taklit etmek için algılama cihazları, yapay zekâ, makine öğrenimi ve derin öğrenmeden gelen girişleri kullanır [1]. Yüz analizi işlemi, kameranın yüz görüntüsünü algılar ve kaydeder. Görüntünün alındığı esnada birçok faktör etkili olur. Bunlardan bazıları: ortamın ışığı, yüzlerin açısı, kullanılan aksesuarlar (gözlük, maske, atkı vs.), sakal/bıyık, estetik operasyonlar ve hatta kozmetik kullanımı gibi faktörlere karşı duyarlıdır. Kaydedilen görüntü analiz edilir. Analiz aşamasında gözler arasındaki mesafe, burun ve dudak yapısı, kırışıklık yoğunluğu, alından çeneye kadar olan mesafe, çene hattı gibi ayırt edici noktalar tanımlanmaktadır. Tanımlanan görüntünün veriye çevrilmesinin ardından veri tabanı ile karşılaştırılır.

Günümüzde yüz tanıma, güvenlikten eğlenceye kadar pek çok sektörde kullanılmaktadır. Örneğin her gün kullandığımız telefonlar da kullanılan yüz kilidi teknolojisi, kayıp kişilerin bulunması, savunma sanayisi, insansız hava araçları, Google harita teknolojisi, mobil bankacılık işlemleri gibi çeşitli alanlarda kullanılır. Güvenlik alanında yapılan çalışmalarla yüz tanıma sistemleri havalimanlarında da yerini almaya başladı. Bu çalışmalar da pasaport kontrol işlemlerinde zaman kazanmak için biyometrik teknoloji kameralar ile kişilerin fotoğrafı çekiliyor ve işlemler daha kısa sürede tamamlanmış oluyor. Aynı zamanda kimlik tespitlerinde ve halka açık alanlarda suçlu aramasında da kullanılabiliyor. Sağlık alanında yüz tanıma sistemleri giyilebilir cihazlarda; örnek olarak Alzheimer hastalarının gözlüğüne yerleştirilen bir kamera ve yüz tanıma yazılımı sayesinde hastaların hatırlamasına yardımcı oluyor.

Görüntü işleme teknolojilerinin kullanılabilmesi için yazılım dillerine özel tasarlanmış kütüphaneler bulunmaktadır. C, C++, Python, Java, Matlab yazılım dillerine; Pillow, NumPy, Scipy, OpenCV, SimpleCV ise kütüphanelere örnektir. Bu çalışmada ise Python yazılım dili ve OpenCV, Keras, Matplotlib ve TensorFlow gibi kütüphaneler kullanılacaktır. Bu çalışmada, yüz tanıma tekniklerini kullanarak yaş, cinsiyet ve duygu tespiti yapılacaktır. UTK Face veri kümesini kullanarak farklı yaş gruplarından ve cinsiyetlerden kişilerin yüz fotoğraflarını içeren bir veri kümesi, duygu analizi için Fer2013 veri kümesini kullanılacaktır. Fer2013 veri kümesi, yedi farklı duygu ifadesini gösteren insanların yüz fotoğraflarını içermektedir. Çalışmanın amacı, yüz tanıma teknikleri ve yapay zekâ algoritmalarını kullanarak, yüz fotoğraflarından yaş, cinsiyet ve duygu durumlarını tahmin etmektir.

## 2. KAYNAK ARAŞTIRMASI

Yoshitomi va. (Yoshitomi va, 1997) yapılan bu çalışmada, termal görüntü işleme tekniklerinden yararlanılarak yüz tanımlama için bir yöntem geliştirmişlerdir. Yöntem, kızılötesi ışınlar kullanılarak yüzün sıcaklık dağılımının 2 boyutlu tespitine dayanmaktadır. Giriş görüntüsündeki önden görünüm yüz, konum ve boyut açısından normalleştirilir, ardından sıcaklık dağılımı, yerel ortalama sıcaklık ve yüzün şekil faktörleri ölçülür. Ölçülen sıcaklık dağılımı ve yerel olarak ortalama sıcaklık, bir sinir ağı için girdi verileri olarak ayrı ayrı kullanılırken, şekil faktörlerinin değerleri denetimli sınıflandırma için kullanılır. NN ve denetimli sınıflandırmadan gelen bilgileri entegre ederek, yüz mükemmel bir doğrulukla tanımlanır. Yüz tanımlamasının doğruluğunun gölge, yansıma gibi aydınlatma koşullarından çok fazla etkilenmesi görünür ışın ile yapılan tanımlamaların eksikliğinin, kızılötesi ışınları kullanan mevcut yöntemle mükemmel bir şekilde üstesinden geldiği düşünülmektedir.

Avuçlu, Başçiftçi (Avuçlu, Başçiftçi 2018) bu çalışmada, yaşı tahmin etmek için otomatik olarak 1313 panoramik dış görüntüsü kullanmışlardır. Bu görüntülere görüntü ön işleme uygulanır. Çalışmada düzeltme işlemi özgün ve yeni geliştirilmiş algoritma ile yapılmıştır. Dental görüntüler otomatik ve dinamik olarak bölütlenir ve öznitelikleri çıkarılarak öznitelik vektörleri oluşturulur. Oluşturulan özellik vektörleri dinamiktir ve Çok Katmanlı Algılayıcı Sinir Ağına girdi olarak sunulur. İsteğe bağlı olarak giriş sayısı azaltma işlemi yapılabilmektedir. Bu çalışmada, yeni ve özgün olarak geliştirilmiş bir algoritma ile dış röntgeni görüntülerinden yaş ve cinsiyet belirlendi. Bazı dış gruplarında en yüksek sınıflandırma oranı %100 ve 0 hata ile yaş tespiti yapılmıştır. Bu çalışma ile adli bilimlerde yaş tespiti daha doğru olacaktır.

Beyin gelişimi ve sağlıklı yaşlanma sürecinde insan beyninde belirli bir morfolojik değişiklik modeli gözlemlenir. İnsanların yaşı, bu tür kalıplar değerlendirilerek beyin görüntülerinden tahmin edilebilir. Ueda va. (Ueda va, 2019) yapmış oldukları çalışmada hacim verilerinin potansiyelinden tam olarak yararlanmak için beyin T1 ağırlıklı görüntülerden 3 Boyutlu Evrişimli Sinir Ağı (3D-CNN) kullanan bir yaş tahmin yöntemi kullanmışlardır.

Tariq va. (Tariq va, 2019) bu makalede, bilgisayarlı görme tekniği kullanılarak silüetlinmiş yüz profillerinden cinsiyet ve etnik kimlik belirlemeye yönelik ilk girişimi göstermektedirler. 441 görüntü üzerinde test edildikten sonra elde edilen sonuçlar, silüetlinmiş yüz profillerinin özellikle etnik kimlik tespiti için çok fazla bilgiye sahip

olduğunu göstermektedir. Sınıflandırma için şekil bağlamına dayalı eşleştirme kullanılmıştır. Test örnekleri çok etnik gruptan oluşuyordu. Cinsiyet için ortalama doğruluk %71.20 ve etnik köken için %71.66 idi. Bununla birlikte, doğruluk, kadınlar için %83.41 (cinsiyet tanımlaması durumunda) ve Doğu ve Güney Doğu Asyalılar için %80.37 (etnik köken tanımlaması durumunda) gibi bazı sınıflar için önemli ölçüde daha yüksektir.

Singh, Goel (Singh, Goel 2020) bu makalede, bir yüz tanıma sistemi geliştirmek için dijital görüntü işlemeyi kullanmaktadır. Herhangi bir yüz verisinin doğrulanması için tüm prosedür iki aşamaya bölünmüştür, ilk aşamada, nesnenin oldukça uzağa yerleştirildiği durumlar dışında yüz algılama hızlı bir şekilde yapılır, ardından ikinci aşama başlatılır. Yüz bir birey olarak tanınır. Daha sonra tüm süreç tekrarlanarak en çok üzerinde düşünülmüş biyometrik teknolojilerden biri olarak kabul edilen bir yüz tanıma modelinin geliştirilmesine yardımcı olur. Temel olarak, yüz tanıma modelinde şu anda takip edilen iki tür teknik vardır: Eigenface yöntemi ve Fisherface yöntemi. Eigenface yöntemi, temel olarak, yüz özelliklerinin yüz boyutsal alanını en aza indirmek için PCA'yı (Temel Bileşen Analizi) kullanır.

Salunke, Panicker (Salunke, Panicker 2020) bu çalışmada, derin öğrenme tekniklerini kullanan görüntü duyarlılığı alanındaki en yeni gelişmeleri dile getirmektedir. Ayrıca, geleneksel makine öğrenmesi tekniklerinin kullanımı, derin öğrenme algoritmaları ile karşılaştırılmıştır. Hızlı tekrarlayan sinir ağları ve CNN'nin bir kombinasyonunun minimum zaman karmaşıklığı ile yüksek doğruluk üretebileceğinin göstergesidir. Anketten, mevcut araştırmacıların CNN'yi yansıttığının, titreşimli görüntü veri setinde duyarlılık sınıflandırması için yaklaşık %96.50 ortalama doğruluk sağladığı belirtilmektedir.

Yap va. (Yap va, 2020) bu makalede, insan yüzü analizi için geliştirilmiş görüntü işlemeye yönelik bir metodolojiyi tartışmakta ve görünür görüntülerden elde edilen sonuçları karşılık gelen termal görüntülerle birleştirmeye çalışmışlardır. İlk olarak, renkli görüntülerde geliştirilmiş bir yüz algılama algoritması anlatılmaktadır. Daha önceki araştırmalarda önerilen çözüm, eğitim setini artırmaktır; bu çalışmada ise renk segmentasyonu uygulayarak renkli görüntüleri önceden işlemektir. Farklı kaynaklardan gelen veri kümeleri test edilir ve üretilen deneysel sonuçlar, bu yaklaşımın bazı veri kümelerinde algılama oranını artırdığını ve yanlış algılama oranını azalttığını saptanmıştır. Bu veri setlerinden elde edilen performanslar karşılaştırılır ve gelecekteki olası uygulamalar tartışılır. Bu makalenin ikinci katkısı, görünür görüntüler ile termal görüntü

arasında bir bağlantı kurmaktır. Termal görüntüdeki yüz özelliklerini konumlandırmak için görünür görüntü bilgilerini uygulama yöntemi gösterilmektedir. Son olarak, güvenlik alanı içinde yüz analizi sonuçlarının gelecekteki olası bazı uygulamaları tartışılmaktadır.

ArıĖ, Turan (ArıĖ, Turan 2020) bu alıřmada, videodaki görüntülerden tespit edilen insan yüzleri üzerinde CNN derin öğrenme modeli ile duygu analizi yapılmıřtır. Bu analize ait sonuçlar saniye saniye kayıt edilerek bir duygu analizi grafiĖi çıkarılmıřtır. alıřma 3 ana safhadan oluřmaktadır. İlki CNN modeli için gerekli duygu yüklü görsellerin bulunup etiketlenmesi, ikincisi duygu analizi yapabilecek bir CNN derin öğrenme modelinin oluřturulması ve üçüncüsü de videolardan yüz görüntülerinin tespit edilmesidir. alıřmada, 50 bin civarı yüz örnekleme elde edilmiřtir. Ancak daha sonra yapılan kontrollerde Haarcascade ile bulunmuř görüntüler arasında yüz olmayan birçok görsel tespit edilerek çıkarılmıřtır. Ayrıca, Amazon web servisinden dönen duygu analizlerinde %40 civarında yanlış duygu tespiti olduđu belirlenerek, eĖitim veri setinden çıkarılmıřtır. Tüm veri seti temizleme alıřmaları sonucunda 7 duygu için etiketlenmiř 20 bin fotoğraf elde edilmiřtir. Önerilen model ile %60'lık doğruluk deęerine ulařılmıřtır.

Rahman va. (Rahman va, 2020) bu alıřmada, yüz görüntülerini kullanarak hem insan yařını hem de cinsiyetini tahmin etmek için tatmin edici alıřma süresi ve verimlilięe sahip iki ayrı yöntem uygulamıřlardır. Görüntü iřleme tabanlı yöntem, eřitli yař aralıklarındaki kiřilerin son iřlemden geirilmiř yüz görüntülerinden elde edilen bazı özelliklerin karřılařtırılması, ardından bazı kenar algılama prosedürleri, ikili maskelerin oluřturulması ve kırıřıklık yoğunluklarının deęerlendirilmesini içermektedir. Sınıfları tahmin etmek için Naive Bayes Sınıflandırması aracılıęıyla eřikler belirlenmiřtir. Deęerlendirme amacıyla, farklı yařlardaki hem erkek hem de kadın görüntülerinden oluřan BUET yüz veri tabanı adlı bir veri tabanı geliřtirilmiřtir. Geliřtirilen veri tabanı için önerilen algoritma yař grubu sınıflandırmasında %76.3 doğruluk gösterirken cinsiyet sınıflandırmasında %86.6 doğruluk göstermektedir.

Göze, Yıldız (Göze, Yıldız 2021) gerekleřtirilen bu alıřmada, video görüntülerinde gerek zamanlı yüz tanıma ve zamanın tespiti için yeni bir derin öğrenme modeli önerilmiřtir. Yapılan deneysel alıřmalarda önerilen Evriřimli Sinir Aęı tabanlı modelin MTCNN, OPENCV-CNN, HOG+SVM, SSD-CAFFEMODEL modellerine göre daha yüksek performansa ve daha yüksek doğruluk oranına sahip olduđu gösterilmiřtir.

### 3. MATERYAL VE YÖNTEM


#### 3.1. Materyaller

Bu çalışmada, derin öğrenme ile görüntü üzerinden yaş, cinsiyet ve duygu analizi yapmak için çeşitli materyaller kullanılmıştır. Materyaller aşağıda detaylı olarak açıklanmıştır.

##### 3.1.1 Derin Öğrenme

Derin öğrenme ilk olarak 1943'te Warren McCulloch ve Walter Pitts'in sinir ağlarını çoğaltan bir bilgi işlem sistemi oluşturmak için matematik ve algoritmaları kullanmasıyla ortaya çıkmıştır. Derin öğrenmenin bir terim olarak teknoloji konuşmalarında net bir form olarak ortaya çıkması ancak 2000'lerin ortalarında gerçekleşebilmiştir. Hinton'un yapmış olduğu çalışmalarla yayınlamış olduğu makalede yapay sinir ağlarına yeni bir yaklaşım getirmiştir. Bu yaklaşım derin öğrenme (Deep Convolution Neural Network) olarak adlandırılmıştır [2].

Derin öğrenme, yapay sinir ağları üzerine kurulu bir makine öğrenmesi yöntemidir [3]. Bu yöntem, bilgisayar sistemlerinin veri üzerinde öğrenme yeteneği kazanmasını sağlar. İnsan beyninin sinir ağlarından esinlenen derin öğrenme, büyük miktarda veri kullanarak karmaşık ilişkileri ve desenleri . algılayabilen bir model geliştirmeyi hedefler. Derin öğrenme algoritmaları, genellikle çok katmanlı sinir ağlarından oluşur [3,4]. Her katman, birbirine bağlı nöronlardan oluşur ve bir önceki katmandan aldığı veriyi işlerken çıktılarını bir sonraki katmana aktarır. İlk katman giriş verilerini işlerken, son katman ise hedeflenen çıktıyı üretir. Aradaki katmanlar, verinin içindeki karmaşıklığı ve özellikleri hiyerarşik olarak temsil eder. Bu sayede, basit özelliklerin birleşimiyle daha soyut ve yüksek seviyeli kavramları öğrenebilir.



(a) Makine Öğrenmesi Katmanları





(b) Derin Öğrenme Katmanları

**Şekil 1.** Makine Öğrenimi ve Derin Öğrenme Mimarisi [5]

Derin öğrenme ağları, birçok ardışık katmanı içeren bir mimariye sahiptir. Bu katmanlar, veri üzerinde farklı hesaplamalar gerçekleştirerek sonuçları elde eder.

1. **Girdi (Input):** Derin öğrenme sürecinde, veri seti veya gözlem verileri girdi olarak kullanılır. Bu girdiler, görüntüler, metinler, sesler veya diğer veri türleri olabilir.
2. **Özellik Çıkarımı (Feature Extraction):** Derin öğrenme ağları, özellik çıkarımı için karmaşık matematiksel işlemler kullanır. Bu aşamada, ağ, girdi verilerinden önemli özelliklerin (örneğin kenarlar, desenler, yüzler) otomatik olarak çıkarılmasını sağlar. Bu adım, veri setinin temsiliğini öğrenmek için yapılan derin hesaplamalardan oluşur.
3. **Sınıflandırma (Classification):** Özelliklerin çıkarıldığı aşamadan sonra, derin öğrenme ağı, verileri farklı sınıflara veya kategorilere atamak için sınıflandırma işlemi gerçekleştirir. Bu adım, modelin öğrendiği temsili, veri noktalarını doğru şekilde etiketlemesini sağlar. Örneğin, bir görüntü sınıflandırma problemi için model, görüntüleri farklı nesne kategorilerine (köpek, kedi, araba, vb.) atayabilir.
4. **Çıktı (Output):** Derin öğrenme modeli, sınıflandırma sonucunda elde edilen çıktıları sağlar. Çıktı, sınıfların olasılık değerlerini, etiketleri veya diğer istenen bilgileri içerebilir. Bu çıktılar, genellikle probleme özgüdür ve kullanıcıya sunulacak sonuçları temsil eder.

### 3.1.2. Görüntü İşleme

Görüntü işleme, elektronik cihazların görüntüler ve videolardaki nesneleri, kişileri tanımlayarak anlamasını sağlayan bir bilgisayar bilim alanıdır [6]. Herhangi bir görüntünün netliğini artırma, görüntü üzerinde bulunan nesnelerin elde edilebilmesi veya


nesnelerin tanımlanabilmesi gibi birçok amaçla kullanılmaktadır. Bu alan, insan görsel sisteminden ilham alarak, algılama cihazları, yapay zekâ, makine öğrenimi ve derin öğrenme gibi teknolojileri kullanır. Görüntü işleme algoritmaları, görüntülerdeki desenleri, yapıları, renkleri ve diğer özellikleri analiz eder ve bu bilgileri kullanarak farklı türdeki görevleri gerçekleştirir [7].

Bir görüntünün sayısal verilere dönüştürülmesi, sayısallaştırma adı verilen bir süreci gerektirir. Bu süreçte, görüntüde bulunan renkler sayısal değerlerle ifade edilir. Her pikselin (görüntünün en küçük bileşen birimi) renk bilgisi bir veya daha fazla sayıyla temsil edilir. Bu sayılar genellikle RGB (Kırmızı, Yeşil, Mavi) formatında kullanılır, her bir renk kanalı için 0 ile 255 arasında değer alır. Böylece, görüntü işleme algoritmaları, piksellerin renk değerlerini kullanarak görüntüleri analiz eder ve istenen sonuçları elde etmek için çeşitli işlemler gerçekleştirir. Görüntü işleme, birçok alanda uygulama potansiyeline sahiptir. Tıp, otomotiv, güvenlik, tarım, robotik ve sanat gibi birçok sektörde kullanılmaktadır. Örnek olarak, tıp alanında görüntü işleme teknikleri, hastalıkların teşhisi, tarama sonuçlarının analizi ve cerrahi planlama gibi birçok alanda büyük bir etki yaratmıştır.

Görüntü işleme teknolojileri sürekli olarak gelişmekte ve yeni fırsatlar sunmaktadır. Derin öğrenme ve yapay zekâ gibi ileri teknikler, görüntü işleme performansını daha da artırmış ve daha karmaşık görevlerin gerçekleştirilmesini sağlamıştır. Bu sayede, daha doğru sonuçlar elde etmek ve insanların görme yeteneğine benzer bir analitik yetenek geliştirmek mümkün olmuştur.


### **3.1.3. Evrişimli Sinir Ağları (CNN-Convolutional Neural Networks)**

Evrişimli sinir ağları, temel olarak görüntüleri sınıflandırmak, benzerliğe göre kümelemek, fotoğraf arama, ses analizi vb. için kullanılan derin YSA modelidir. Giriş, evrişim ve tam bağlantı katmanı olmak üzere üç katmandan oluşmaktadır. Giriş katmanı verilerin girildiği katmandır. Evrişim katmanında, yapıya uygun olarak belirlenmiş bir filtrenin, giriş matrisinin pikselleri üzerinde teker teker kaydırılması işlemidir. Kaydırma sırasında filtredeki değerler görüntünün orijinal piksel değerleri ile çarpılarak toplanır ve tek değer halinde yazılır. Bu işlem, tüm girdi matrisi boyunca hesaplanır. Sonuç olarak belirgin yüksek seviyeli niteliklere dayalı yeni bir görüntü elde edilir [8].



Şekil 2. Evrişim Uygulaması

Havuzlama katmanı, boyut azaltmak için kullanılan bir işlemdir. Ancak boyut azaltma işlemleri bazı bilgilerin kaybolmasına neden olmaktadır. Bununla birlikte havuzlama işlemi, modelin ezberlemesini önlemek ve daha az hesaplama yükü oluşturmak gibi avantajlara sahiptir. Havuzlama işlemi ortalama, minimum ve genellikle maksimum havuzlama yöntemleri uygulanarak gerçekleştirilir [9].



Şekil 3. Havuzlama İşlemi

Tam bağlantı katmanı, havuzlama işlemi sonucu elde edilen çıktı bu katmanda tek boyutlu vektöre dönüştürülür. Bunun nedeni tek boyutlu vektöre dönüşmüş olan girdinin yapay sinir ağına eklenecek olmasıdır. Bir boyuta dönüştürme işlemini tam bağlantılı katmanda bulunan düzleştirici (flatten) gerçekleştirir.



Şekil 4. Flatten İşlemi

Görüntü işleme alanında kullanılan Evrişimli Sinir Ağları (Convolutional Neural Networks, CNN) önemli bir rol oynamaktadır. CNN'ler, görüntü verilerinin analizi ve işlenmesi için özel olarak tasarlanmış derin öğrenme modelleridir. Geleneksel sinir ağlarından farklı olarak, CNN'ler, verinin 2B yapısını ve özelliklerini koruyarak daha etkili bir şekilde çalışır. CNN modeli, analizlerimizdeki en önemli ve etkili model olarak ortaya çıkmıştır. Bu çalışmada tercih edilen model olması, çeşitli avantajlara sahip olmasından kaynaklanmaktadır. Avantajları, görüntülerdeki özelliklerin hiyerarşik olarak öğrenilmesini sağlayan konvolüsyon ve havuzlama katmanları sayesinde, görüntülerin özünü yakalama ve anlamlı temsil oluşturma yetenekleri vardır. Ayrıca, CNN özel mimarisi, farklı boyutlarda ve türlerde (renkli, siyah beyaz, vb.) görüntülerle kolayca çalışabilme esnekliği sağlar. Bir diğer avantajı parametre paylaşımıdır. Diğer modellere göre daha az parametre gerektirir, bu da daha az hesaplama maliyeti ve daha hızlı öğrenme anlamına gelir. Ayrıca, daha az parametre kullanımı, aşırı uyum (overfitting) riskini azaltabilir.

Sonuç olarak, CNN modelleri, görüntü işleme problemlerinde etkili sonuçlar elde etmek için özel olarak tasarlanmıştır. Özel mimarisi, parametre paylaşımı ve uyumluluk yetenekleri, CNN'leri analizlerimizdeki en önemli ve etkili model haline getirmektedir. Ancak başka model türleri de kullanılabilir. Alternatif model türlerinden aşağıda kısaca bahsedilmiştir.

1. Transfer Öğrenme Modelleri: Önceden eğitilmiş büyük ölçekli modeller, özellikle görüntü tanıma alanında, duygusal yüz ifadesi ve yaş, cinsiyet tanıma için kullanılabilir. Örneğin, VGGNet, ResNet, Inception, MobileNet gibi popüler modeller, transfer öğrenme yaklaşımıyla duygusal yüz ifadesi tanıma problemini çözebilir. Bu modeller, önceden büyük veri setleri üzerinde eğitilmiş ve genel özellikleri öğrenmiş olduğu için, daha küçük bir veri setinde duygusal yüz ifadelerini tanıma görevi için kullanılabilir.
2. LSTM (Uzun Kısa Süreli Hafıza) Modelleri: LSTM'ler, ardışık verilerin analizi ve zaman serileri problemleri için kullanılan bir tür yapay sinir ağıdır. Yüz ifadelerinin zaman içindeki değişimini yakalamak için LSTM tabanlı modeller kullanılabilir. Görüntülerin veya görüntü dizilerinin özelliklerini çıkarmak için önceden eğitilmiş bir CNN kullanılarak elde edilen özellikler, ardından LSTM modeline beslenebilir.
3. HMM (Gizli Markov Modeli): HMM'ler, ardışık verileri analiz etmek için kullanılan istatistiksel bir modeldir. Duygusal yüz ifadelerinin ve yaş, cinsiyet

analizinin zaman içindeki değişimini ve geçişlerini modellemek için HMM tabanlı bir yaklaşım kullanılabilir. Görüntü dizileri üzerinde özellik çıkarma işlemi yapmak için önceden eğitilmiş bir model kullanılabilir ve ardından HMM ile sınıflandırma yapılabilir.

4. SVM (Destek Vektör Makineleri): SVM'ler, sınıflandırma problemleri için kullanılan bir makine öğrenmesi modelidir. Görüntülerden elde edilen özellikleri kullanarak SVM tabanlı bir sınıflandırma modeli oluşturulabilir. Özellik çıkarma işlemi için önceden eğitilmiş bir CNN veya başka bir görüntü işleme yöntemi kullanılabilir.

### 3.1.4. Kütüphaneler

OpenCV (“Open Computer Vision”), Intel tarafından geliştirilmiş Windows, Linux, Mac OS X, PSP (PlayStation Portable) platformları üzerinde çalışabilen, C diliyle yazılmış ve daha sonra birçok algoritması C++ dili ile geliştirilmiştir. Açık kaynak kodlu bir “Bilgisayarla Görme” kütüphanedir [10]. Amacı bir resim ya da video içindeki anlamlı bilgileri çıkarıp işleyebilmektir. İlk sürümü 1999 yılında çıkarılmıştır. OpenCV kütüphanesi, gerçek zamanlı uygulamalar hedef alınarak geliştirilmiştir.

OpenCV kütüphanesi içerisinde görüntü işlemeye (image processing) ve makine öğrenmesine (machine learning) yönelik 2500’den fazla algoritma bulunmaktadır. Bu algoritmalar ile yüz tanıma, nesneleri ayırt etme, insan hareketlerini tespit edebilme, nesne sınıflandırma, plaka tanıma, üç boyutlu görüntü üzerinde işlem yapabilme, optik karakter tanımlama OCR (Optical Character Recognition) gibi işlemler rahatlıkla yapılabilmektedir [11].

Kütüphane Adı	İşlevi
Seaborn	Matplotlib kütüphanesi üzerine inşa edilen Seaborn, istatistiksel grafiklerin çizilmesi ve veri keşfinin kolaylaştırılması için bir dizi yüksek seviye araç sağlar [12].
Sklearn	Sınıflandırma, regresyon, kümeleme ve boyut indirgeme gibi makine öğrenimi algoritmalarını içerir ve veri setlerinin yüklenmesi, model seçimi, eğitimi ve değerlendirmesi gibi işlemleri kolaylaştırır.


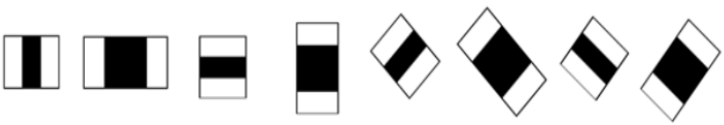

Keras	Derin öğrenme çalışmaları yapmak amacıyla sunulan, yapay zekâ ve makine öğrenmesi yöntemlerini içeren bir kütüphanedir. Yüksek performanslı işlemler yapabilen ve derin öğrenme çalışmaları için kullanılan Theano ve TensorFlow kütüphaneleri üzerinden çalışmaktadır [13].
Matplotlib	Grafikler, tablolar, diyagramlar ve diğer görsel formatlarla verileri sunma yeteneği sağlar. Basit çizimlerden karmaşık görselleştirmelere kadar geniş bir yelpazede kullanılabilir ve özelleştirme imkânı sunar.
TensorFlow	TensorFlow, açık kaynaklı bir yapay zekâ ve makine öğrenmesi yazılım kütüphanesidir. Derin öğrenme modelleri oluşturmak, eğitmek ve dağıtmak için kullanılır.
NumPy	Çok boyutlu diziler ve matrisler üzerinde hızlı matematiksel işlemler yapmak için kullanılır. Temel veri yapısı ndarray, daha verimli bir şekilde çalışır. NumPy, matematiksel fonksiyonlar ve diğer Python kütüphaneleriyle uyumludur. Veri analizi ve bilimsel hesaplamalar için önemli bir araçtır.

**Tablo 1.** Kullanılan Kütüphaneler

### 3.1.5. Haar Cascade Sınıflandırıcısı

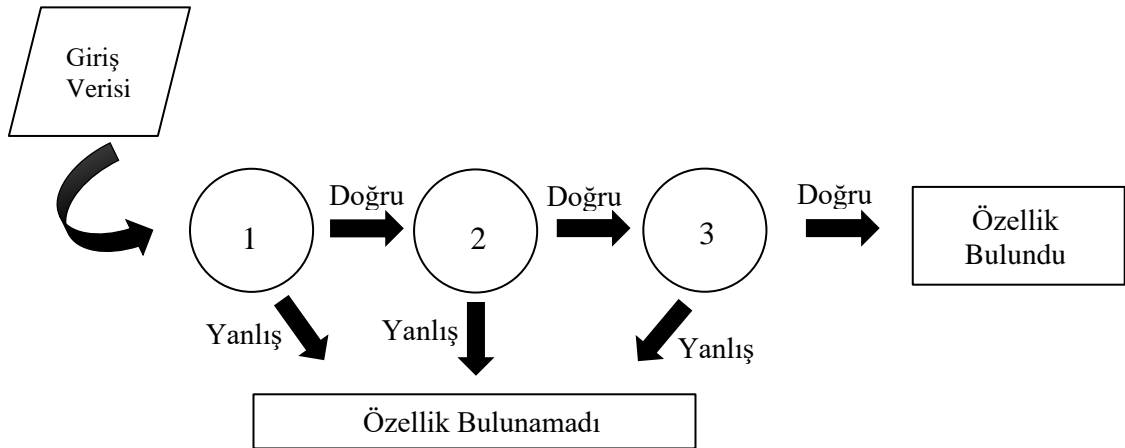
OpenCV kütüphanesi içerisinde bulunan haar cascade sınıflandırıcısı, Paul Viola ve Micheal Jones tarafından oluşturulmuştur. Haar cascade sınıflandırıcı algoritması; dijital bir resim veya video karesi içerisinde bulunan belirli bir nesnenin tespit edilmesi amacıyla kullanılmaktadır [14]. Temelde belirli bir algoritmaya göre bulunması istenen nesneler önce bilgisayara tanıtılır ardından ona benzer şekillerin bulunduğu resimler veya video kareleri taranarak o nesne bulunmaya çalışılmaktadır.

Haar cascade sınıflandırıcısında yüze ait kısımlardan alınmış, aynı boyuttaki resimlerle (pozitif resimler) ve yüz içermeyen diğer kısımlardan alınmış aynı boyuttaki resimler (negatif resimler) kullanılarak eğitilir [15]. Eğitilmiş sınıflandırıcıya yüz içeren bir resim parametre olarak verildiğinde yüzün bulunduğu alan için sınıflandırıcı “1” çıkışını diğer bölgeler için “0” çıkışını vermektedir. Haar öznitelik vektörleri Tablo2.’da verilmiştir [16].

Öznitelik Çeşidi	Özellik Resimleri
Kenar öznitelikleri	
Satır öznitelikleri	
Merkez-çevre öznitelikleri	

**Tablo 2.** Haar Cascade Sınıflandırıcıda Kullanılan Haar Öznitelikleri

Parametre olarak gelen resimdeki yüze ait alanların bulunması işlemi tüm resim taranarak gerçekleştirilmektedir. Sınıflandırıcı farklı boyutlardaki yüz özelliklerini bulacak şekilde ayarlanabilmektedir [17]. Böyle olmasının avantajı ise görüntünün boyutlarını değiştirmeden işlem yaparak daha verimli bir yöntem olarak kullanılmaktadır. Resim içindeki değişik ölçeklerdeki yüz niteliklerini bulabilmek için sınıflandırıcı aynı arama sürecini farklı ölçeklerle tekrar tekrar dener.



**Şekil 5.** Cascade Sınıflandırıcı İşlem Süreci


“Cascade” kelimesi, meydana gelen sınıflandırıcının basit yapılı birden fazla sınıflandırıcının bir araya gelerek karmaşık yapılı bir yapı meydana getirdiğini göstermek amacıyla adlandırılmıştır (Şekil 4). Basit yapılı bu sınıflandırıcılar, herhangi bir

sınıflayıcı katman geri çevirmediği sürece tüm katmanlar geçilene kadar parametre olarak verilen resme art arda uygulanır [18].



**Şekil 6.** Haar Özellikler ve Uygulamaları (Burun ve Yanak)

Yukarıdaki pencere için yanakların parlaklık oranının burun bölgesindeki parlaklık oranından daha düşük olması ile burun kısmı seçilebilir.































**Şekil 7.** Haar Özellikler ve Uygulamaları

Yukarıdaki (Şekil 6.) yüz taramasında ağız, burun, alın, yanak ve saç gibi bölgelerde birçok aydınlık-karanlık özellikleri oluşturulacaktır [19]. Bunların her birinden hedef değerler oluşturulmaktadır ve bu işlem pencere büyüklükleri değiştirilerek diğer aşamalarda tekrar edilmektedir.

### 3.1.6. Fer2013 Veri Kümesi

Fer2013 veri kümesi, yüz ifade tanıma alanında yapay zeka, derin öğrenme ve makine öğrenimi modellerinin geliştirilmesi ve test edilmesi için sıkça kullanılan bir kaynaktır. Pierre-Luc Carrier ve Aaron Courville tarafından devam etmekte olan bir proje için oluşturulmuştur. Kaggle üzerinde gerçekleştirilen bir yüz ifade analizi yarışması için oluşturulan veri seti, 28709'u eğitim, 3589'u doğrulama ve 3589'u test verisi olmak üzere 7 ifade sınıfına ait toplam 35887 48x48 boyutunda gri-seviye yüz ifadelerini barındırmaktadır [20].



Kızgın	İğrenme	Korku	Mutlu	Üzgün	Şaşkın	Nötr
						
						
						
						
4953 %13.8	547 %1.5	5121 %14.2	8989 %25.0	6077 %16.9	4002 %11.1	6198 %17.2

**Şekil 8.** Fer2013 Veri Kümesindeki Sınıflara Ait Örnekler, Örnek Sayısı ve Dağılımı  
[21]

Paylaşılan veri kümesi içerisinde her bir satırda resimlerin piksellere dönüştürülmüş BGR renk kodları bulunmaktadır. Her satırın ilk sütunu o resme etiketlenmiş olan duygu durumunu belirtmektedir.

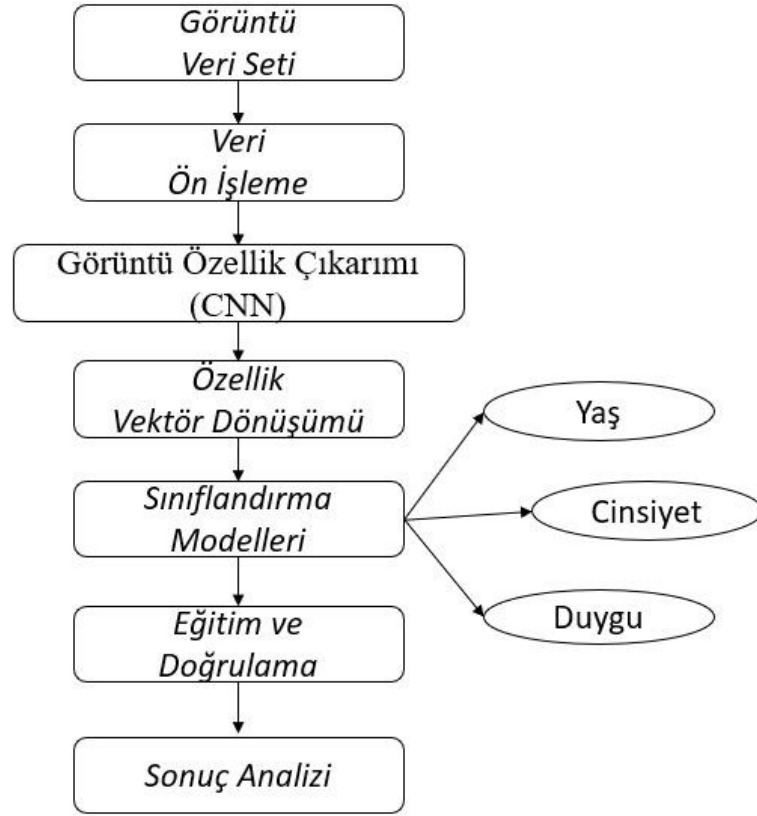
### 3.1.7. UTK Face Veri Kümesi

UTK Face veri kümesi, yüz tanıma araştırmalarında kullanılan bir veri kümesidir, yüz tanıma teknikleri ve yapay zekâ algoritmalarının geliştirilmesine katkıda bulunmak amacıyla oluşturulmuştur. Bu veri kümesi, insanların farklı yaş aralıklarında çekilmiş yüz fotoğraflarını içerir. Fotoğraflar, farklı ırklardan, etnik kökenlerden ve coğrafi bölgelerden insanlara aittir. Her fotoğrafın yanında, kişinin yaş, cinsiyet ve etnik köken bilgileri de yer alır. 200x200 piksel boyutunda 23.708 renkli görüntü içerir [22]. UTK Face veri kümesi, geniş bir demografik çeşitliliğine sahip olduğu için yüz tanıma algoritmalarının geçerliliğini ve performansını değerlendirmek için önemli bir kaynaktır.

Sonuç olarak, UTK Face veri kümesi, yüz tanıma araştırmalarında geniş kapsamlı bir değerlendirme yapmak ve algoritmaların yaş, cinsiyet ve etnik köken tahmini gibi özellikleri doğru bir şekilde tespit etme yeteneklerini değerlendirmek için bir kaynaktır [23].

### 3.2. Yöntem

Görüntü tabanlı cinsiyet, yaş ve duygu analizi, çağdaş araştırmalarda büyük ilgi uyandıran bir konudur. Günümüzde derin öğrenme teknikleri, bu tür analizlerde önemli bir başarı sağlamış ve geniş bir uygulama alanına sahip olmuştur. Bu çalışmada, derin öğrenme yöntemlerinin kullanılmasıyla, görüntüler üzerinde cinsiyet, yaş ve duygu analizinin nasıl gerçekleştirilebileceği üzerine bir çalışma yapılmıştır. Aşağıda (Şekil 10.) bu çalışmanın akış diyagramı verilmiştir.

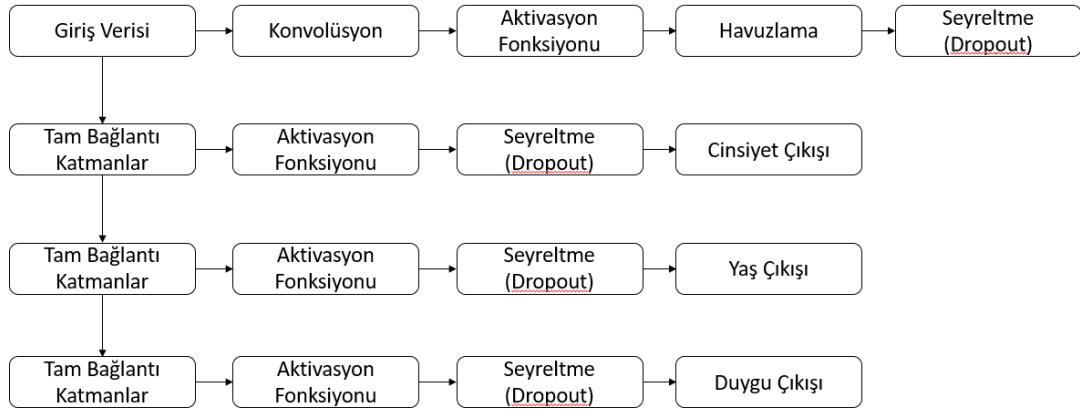


Şekil 9. Akış Diyagramı

Bu akış diyagramı, görüntü veri seti üzerinde gerçekleştirilen çoklu analiz sürecini açıklamaktadır. İlk adımda, görüntü veri seti üzerinde veri ön işleme işlemleri gerçekleştirilir, bu adımda görüntülerin boyutu yeniden ölçeklendirilir ve diğer ön işleme adımları uygulanır. Ardından, bir evrişimli sinir ağı (CNN) kullanılarak görüntü özellik çıkarımı gerçekleştirilir. CNN, görüntüden özellikleri çıkarmak için filtreler ve evrişim işlemleri kullanır. Özellik çıkarımı aşamasından sonra, elde edilen özellikler bir özellik vektörüne dönüştürülür. Bu özellik vektörü, görüntüdeki önemli özelliklerin temsilini sağlar. Ardından, sınıflandırma modelleri kullanılarak yaş, cinsiyet ve duygu gibi çeşitli

etiketlerin sınıflandırması gerçekleştirilir. Bu modeller, özellik vektörünü girdi olarak alır ve ilgili etiketleri tahmin etmek için eğitilir. Eğitim ve doğrulama aşamasında, sınıflandırma modelleri eğitim veri seti üzerinde eğitilir ve ardından doğrulama veri seti üzerinde test edilir. Performans değerlendirmesi için çeşitli metrikler kullanılır ve sonuç analizi gerçekleştirilir. Bu analiz aşamasında, modelin doğruluk, hassasiyet, geri çağırma gibi performans ölçütleri değerlendirilir ve sonuçlar yorumlanır. Bu akış diyagramı, görüntü veri seti üzerinde çoklu analiz yapmak için adımları ve süreçleri görselleştirerek, görüntü tabanlı analiz sürecinin genel bir özetini sunar.

Yöntem olarak, daha öncede belirtildiği gibi evrişimli sinir ağıları (Convolutional Neural Networks- CNN) kullanılmıştır. İlk adımda, geniş bir veri kümesi toplanılmış ve etiketlenmiştir. Bu veri kümesi, insan yüzlerinin görüntülerini içerir ve her bir görüntü için cinsiyet, yaş ve duygu etiketleri ile ilişkilendirilmiştir. Ardından, CNN modeli oluşturulmuş ve eğitim veri seti üzerinde eğitilmiştir. Model, derinlikli evrişim katmanları, havuzlama katmanları, tam bağlantılı katmanlar ve çıkış katmanından oluşmuştur. Eğitim sürecinde, veri artırma teknikleri kullanılmış ve modelin genelleme yeteneği artırılmıştır. Son olarak, eğitilen model, test veri seti üzerinde değerlendirilmiş; cinsiyet, yaş ve duygu analizi için tahminler yapılmıştır. Elde edilen sonuçlar; doğruluk oranları, hata matrisleri ve diğer performans ölçütleri kullanılarak değerlendirilmiştir.



**Şekil 10.** CNN Akış Diyagramı

Bu akış diyagramı, derin öğrenme ile cinsiyet, yaş ve duygu analizi yapmak için kullanılan bir modeli temsil etmektedir.

- Giriş Verisi: Modelin girişine görüntü verileri sağlanır. Bu genellikle yüz görüntüleri olup, boyutları belirli bir genişlik, yükseklik ve kanal sayısı ile ifade edilir.
- Konvolüsyon: Konvolüsyon katmanları, giriş görüntüsü üzerinde farklı filtreler uygular. Bu filtreler, görüntüdeki özellikleri (kenarlar, köşeler, desenler vb.) belirlemeye yardımcı olur. Her konvolüsyon katmanı genellikle daha karmaşık özellikleri öğrenmek için daha fazla filtre içerir.
- Aktivasyon Fonksiyonu: Konvolüsyon sonrasında her çıktıya bir aktivasyon fonksiyonu uygulanır. ReLU (Rectified Linear Unit) yaygın olarak kullanılan bir aktivasyon fonksiyonudur. Bu fonksiyon, çıktıyı doğrusal olmayan hale getirir ve modelin daha genel özellikler öğrenmesini sağlar.
- Havuzlama: Havuzlama (Pooling) katmanları, konvolüsyon çıktılarını küçültmek ve önemli özellikleri korumak için kullanılır. Genellikle en büyük değeri veya ortalama değeri olarak küçültme işlemi gerçekleştirir.
- Seyreltme: Seyreltme (Dropout) katmanları, modelin aşırı uyum yapmasını engellemek için kullanılır. Rastgele birimleri kapatır ve ağırlıkların dağılımını dengeleyerek modelin genelleme yeteneğini artırır.
- Tam Bağlantılı Katmanlar: Önceki katmanların çıktılarını girdi olarak alarak, özellikler arasındaki ilişkileri öğrenir ve son tahmin sonuçlarını üretir.
- Cinsiyet Çıkışı: Tam bağlantılı katmanlardan biri, cinsiyet tahminini yapmak için kullanılır. Bu katman genellikle sigmoid aktivasyon fonksiyonu ile sonlanır ve iki sınıf (erkek ve kadın) için bir olasılık değeri üretir.
- Yaş Çıkışı: Bir başka tam bağlantılı katman, görüntü üzerinden yaş tahmini yapmak için kullanılır. Bu katman genellikle lineer aktivasyon fonksiyonu ile sonlanır ve sürekli bir sayısal değer olan yaş için bir tahmin üretir.
- Duygu Çıkışı: Diğer bir tam bağlantılı katman, görüntüdeki duyguyu tahmin etmek için kullanılır. Bu katman genellikle softmax aktivasyon fonksiyonu ile sonlanır ve duygusal kategoriler için olasılık dağılımı sağlar (örneğin, mutlu, üzgün, kızgın vb.).

Kullanılan model; cinsiyet, yaş ve duygusal yüz ifadesini tanımak için evrişimli sinir ağı (CNN) mimarisini kullanan bir Sequential modelidir. Aşağıdaki bölümde modelin mimarisi ayrıntılı olarak tanımlanmıştır.

```
model = Sequential()
model.add(Conv2D(32, kernel_size=(3, 3), activation='relu',
input_shape=(48,48,1)))
model.add(Conv2D(64, kernel_size=(3, 3), activation='relu'))
model.add(MaxPooling2D(pool_size=(2, 2)))
model.add(Dropout(0.1))
model.add(Conv2D(128, kernel_size=(3, 3), activation='relu'))
model.add(MaxPooling2D(pool_size=(2, 2)))
model.add(Dropout(0.1))
model.add(Conv2D(256, kernel_size=(3, 3), activation='relu'))
model.add(MaxPooling2D(pool_size=(2, 2)))
model.add(Dropout(0.1))
model.add(Flatten())
model.add(Dense(512, activation='relu'))
model.add(Dropout(0.2))
model.add(Dense(7, activation='softmax'))
```

Yukarıdaki model, evrişimli (convolutional) ve tamamen bağlı (fully connected) katmanlardan oluşur. Evrişimli katmanlar, görüntüleri özellik haritalarına dönüştürmek için evrişim operasyonlarını uygular. Ardışık evrişim ve maksimum havuzlama (pooling) katmanları kullanılarak özellikler daha da özütlenir. Daha sonra, tamamen bağlı katmanlar ve dropout katmanlarıyla birlikte modelin sınıflandırma yapmasını sağlayan bir softmax aktivasyonlu çıkış katmanı eklenir. Model, Adam optimizer ile "categorical\_crossentropy" kayıp fonksiyonu kullanarak derlenir ve ardından eğitim ve doğrulama veri setleri üzerinde belirli bir sayıda epoch için eğitilir. Sonuç olarak, modelin performansı değerlendirilir ve eğitilen model kaydedilir. Ayrıca, doğrulama veri seti üzerinde yapılan tahminlerin gerçek etiketlerle karşılaştırıldığı bir karmaşıklık matrisi (confusion matrix) oluşturulur ve görselleştirilir.

## 4. ARAŞTIRMA SONUÇLARI VE TARTIŞMA

### 4.1. Araştırma Sonuçları

Derin öğrenme ile gerçekleştirilen yaş, cinsiyet ve duygu analizi sonuçları olumlu bir başarı elde etmiştir. Analizler, kullanılan veri kümesi üzerinde yüksek doğruluk oranlarıyla yaş tahmini, cinsiyet belirleme ve duygu tespiti yapılabildiğini göstermektedir. Elde edilen sonuçlar aşağıda aktarılmıştır.

#### 4.1.1. Veri Kümesi ve Özelliklerinin Değerlendirilmesi

Yapılan çalışmada, yaş, cinsiyet ve duygu analizi için UTK Face veri kümesi ve Fer2013 veri kümesi kullanılmıştır. UTK Face veri kümesi geniş bir demografik çeşitlilik sunarken, Fer2013 veri kümesi farklı duygu ifadelerini içeren yüz fotoğraflarını içermektedir. Her iki veri kümesinin de analizler için uygun olduğunu değerlendirilmiştir. Veri kümesinin boyutu, veri kalitesi ve demografik özelliklerinin çeşitliliği sonuçlar açısından önemlidir.

#### 4.1.2. Yaş ve Cinsiyet Tespiti Analiz Sonuçları

Yapılan yaş ve cinsiyet tespiti analiz sonuçları, derin öğrenme ile yüz tanıma tekniklerinin yaş, cinsiyet tespit ederek değerlendirilmesini sağlamıştır. UTK Face veri kümesi ile 100 eğitim gerçekleştirilmiştir. Burada eğitim sayısı ve veri kümesindeki veri miktarının artırılmasıyla tahmin oranında arttığı görülmüştür. Örnek olarak 1., 10., 20., 30., 40., 50., 60., 70., 80., 90. ve 100. eğitimlerin sonuçları görülmektedir. 1. eğitimdeki doğruluk oranı %62 civarında iken 100. eğitim sonunda %99 civarında doğruluk oranı elde edilmiştir. Elde edilen sonuçlar, önemli bir doğruluk oranına sahiptir ve çalışmalar literatürdeki benzer çalışmalarla tutarlılık göstermiştir. Bununla birlikte, bazı yaş gruplarında daha fazla hata oranı olduğu gözlemlenmiştir. Özellikle çocuk ve yaşlı gruplarda tahmin hataları daha fazla olmuştur. Bu sonuçlar, yaşa bağlı olarak yüzlerdeki değişimlerin daha zorlu bir görev olduğunu ve gelecekteki çalışmalarda daha fazla iyileştirme yapılması gerektiğini göstermektedir [24]. Aynı şekilde, bazı nadir durumlarda yanlış cinsiyet tahminleri yapıldığı gözlemlenmiştir. Bu durum, veri kümesindeki cinsiyet dengesinin ve bazı yüz özelliklerinin cinsiyet tahminindeki etkisinin daha detaylı olarak incelenmesi gerektiğini göstermektedir. Gelecekteki çalışmalarda, bu alanlarda daha fazla araştırma yapılması ve algoritmaların daha gelişmiş hale getirilmesi önemlidir.

Örnek epoch sonuçları aşağıdaki gibidir.

Epoch 1/100

89/89 [=====] - 10s 88ms/step - loss: 2.5091 -

**accuracy: 0.6262** - val\_loss: 0.7272 - val\_accuracy: 0.6500

Epoch 10/100

89/89 [=====] - 7s 83ms/step - loss: 0.3473 -

**accuracy: 0.8502** - val\_loss: 0.3552 - val\_accuracy: 0.8394

Epoch 20/100

89/89 [=====] - 7s 81ms/step - loss: 0.2599 -

**accuracy: 0.8971** - val\_loss: 0.3347 - val\_accuracy: 0.8777

Epoch 30/100

89/89 [=====] - 7s 80ms/step - loss: 0.1308 -

**accuracy: 0.9524** - val\_loss: 0.3542 - val\_accuracy: 0.8894

Epoch 40/100

89/89 [=====] - 7s 78ms/step - loss: 0.1120 -

**accuracy: 0.9610** - val\_loss: 0.5074 - val\_accuracy: 0.8840

Epoch 50/100

89/89 [=====] - 7s 81ms/step - loss: 0.0826 -

**accuracy: 0.9681** - val\_loss: 0.3979 - val\_accuracy: 0.8936

Epoch 60/100

89/89 [=====] - 7s 79ms/step - loss: 0.0858 -

**accuracy: 0.9659** - val\_loss: 0.4790 - val\_accuracy: 0.8894

Epoch 70/100

89/89 [=====] - 7s 80ms/step - loss: 0.0536 -

**accuracy: 0.9798** - val\_loss: 0.5339 - val\_accuracy: 0.8915

Epoch 80/100

89/89 [=====] - 7s 80ms/step - loss: 0.0324 -

**accuracy: 0.9894** - val\_loss: 0.7631 - val\_accuracy: 0.8968

Epoch 90/100


89/89 [=====] - 7s 82ms/step - loss: 0.0224 -

**accuracy: 0.9933** - val\_loss: 0.7540 - val\_accuracy: 0.8809

Epoch 100/100

89/89 [=====] - 7s 80ms/step - loss: 0.0037 -

**accuracy: 0.9989** - val\_loss: 0.9091 - val\_accuracy: 0.8915



**Grafik 1.** Yaş ve Cinsiyet Analizi Doğruluk Oranları

#### 4.1.3. Duygu Tespiti Analiz Sonuçları

Yapılan duygu tespiti analiz sonuçları, derin öğrenme ile yüz tanıma tekniklerinin duygu durumunu tespit ederek değerlendirilmesini sağlamıştır. Fer2013 veri kümesi ile 100 eğitim gerçekleştirilmiştir. Burada eğitim sayısı ve veri kümesindeki veri miktarının artırılmasıyla tahmin oranında arttığı görülmüştür. Örnek olarak 1., 10., 20., 30., 40., 50., 60., 70., 80., 90. ve 100. eğitimlerin sonuçları görülmektedir. 1. eğitimdeki doğruluk oranı %26 civarında iken 100. eğitim sonunda %61 civarında doğruluk oranı elde edilmiştir. Elde edilen sonuçlar, genel olarak yüksek bir doğruluk oranı göstermiştir ve farklı duygu ifadeleri doğru bir şekilde sınıflandırmada başarılı olmuştur. Ancak bazı duygusal ifadelerde daha düşük bir doğruluk oranı tespit edilmiştir. Örneğin, öfke veya şaşkınlık gibi yoğun duygusal ifadeler, daha karmaşık ve zorlu bir sınıflandırma görevi olarak ortaya çıkmıştır. Bu sonuçlar, duygusal analizde daha fazla hassasiyet ve doğruluk sağlamak için gelişmiş algoritmaların ve derin öğrenme tekniklerinin kullanılması gerektiğini göstermektedir.

Örnek epoch sonuçları aşağıdaki gibidir.

Epoch 1/100

897/897 [=====] - 19s 18ms/step - loss: 1.7865 - **accuracy: 0.2646** - val\_loss: 1.7023 - val\_accuracy: 0.3270



Epoch 10/100

897/897 [=====] - 14s 16ms/step - loss:  
1.2990 - **accuracy: 0.5029** - val\_loss: 1.2060 - val\_accuracy: 0.5359

Epoch 20/100

897/897 [=====] - 15s 17ms/step - loss:  
1.1989 - **accuracy: 0.5427** - val\_loss: 1.1073 - val\_accuracy: 0.5771

Epoch 30/100

897/897 [=====] - 15s 17ms/step - loss:  
1.1477 - **accuracy: 0.5607** - val\_loss: 1.0648 - val\_accuracy: 0.5905

Epoch 40/100

897/897 [=====] - 14s 16ms/step - loss:  
1.1162 - **accuracy: 0.5762** - val\_loss: 1.0545 - val\_accuracy: 0.5999

Epoch 50/100

897/897 [=====] - 15s 17ms/step - loss:  
1.0936 - **accuracy: 0.5870** - val\_loss: 1.0403 - val\_accuracy: 0.6027

Epoch 60/100

897/897 [=====] - 15s 17ms/step - loss:  
1.0791 - **accuracy: 0.5925** - val\_loss: 1.0473 - val\_accuracy: 0.6062

Epoch 70/100

897/897 [=====] - 15s 17ms/step - loss:  
1.0623 - **accuracy: 0.5989** - val\_loss: 1.0288 - val\_accuracy: 0.6177

Epoch 80/100


897/897 [=====] - 15s 17ms/step - loss:  
1.0442 - **accuracy: 0.6064** - val\_loss: 1.0249 - val\_accuracy: 0.6219

Epoch 90/100

897/897 [=====] - 18s 20ms/step - loss:  
1.0329 - **accuracy: 0.6123** - val\_loss: 1.0600 - val\_accuracy: 0.6127

Epoch 100/100


897/897 [=====] - 17s 19ms/step - loss:  
1.0289 - **accuracy: 0.6150** - val\_loss: 1.0359 - val\_accuracy: 0.6162




**Grafik 2.** Duygu Analizi Doğruluk Oranları

#### 4.1.4. Analiz Sonuçları Ekran Görüntüleri


Aşağıda, projenin görüntü çıktıları yer almaktadır. Bu çıktılar, derin öğrenme tekniklerinin yaş, cinsiyet ve duygu analizi gibi alanlarda etkin bir şekilde kullanılabileceğini göstermektedir. Bu çalışma, ileriye dönük görüntü analizi ve derin öğrenme araştırmaları için bir temel oluşturmaktadır. İlerleyen süreçte daha kapsamlı çalışmalar yapılarak elde edilen bulgular daha da geliştirilebilir.




**Şekil 11.** Ekran Görüntüsü (Şaşırmış)



Şekil 12. Ekran Görüntüsü (Kızgın)



Şekil 13. Ekran Görüntüsü (Mutlu)



**Şekil 14.** Ekran Görüntüsü (Üzgün)

#### 4.2. Tartışma

Elde edilen sonuçlar, yaş, cinsiyet ve duygu analizi üzerine yapılan çalışmaların başarılı bir şekilde gerçekleştirilebileceğini ve yüz tanıma tekniklerinin bu özellikleri doğru bir şekilde tespit etme yeteneklerini gösterdiğini göstermektedir. Bununla birlikte, bazı kısıtlamalar ve geliştirilmesi gereken alanlar da mevcuttur. Öncelikle, veri kümesinin genişletilmesi ve çeşitlendirilmesi önemlidir. Daha fazla demografik çeşitlilik, farklı coğrafi bölgelerden ve etnik kökenlerden insanları içeren veri setlerinin kullanılması sonuçların geçerliliğini artırabilir. Ayrıca, veri ön işleme yöntemlerinin ve veri temizleme tekniklerinin iyileştirilmesi, daha yüksek doğruluk ve performans sağlayabilir. Diğer bir önemli nokta, algoritmaların duygu analizi konusunda daha hassas ve genelleştirici hale getirilmesidir. Yoğun duygu ifadelerin daha doğru bir şekilde sınıflandırılabilmesi için daha derin bir analiz ve öğrenme mekanizması gerekmektedir. Bu, daha fazla veri toplama ve daha gelişmiş özellik çıkarımı tekniklerinin kullanılmasını gerektirebilir. Sonuç olarak, bu çalışma yaş, cinsiyet ve duygu analizi üzerine yapılan araştırmaların önemini vurgulamış ve yüz tanıma tekniklerinin bu alanlarda başarılı sonuçlar elde edebileceğini göstermiştir.

## 5. SONUÇLAR VE ÖNERİLER

### 5.1. Sonuçlar

Derin öğrenme yöntemleri kullanılarak görüntü üzerinden yaş, cinsiyet ve duygu analizinin gerçekleştirilmiştir. UTK Face ve Fer2013 veri setleri üzerinde bir CNN modeli oluşturulmuştur. Elde edilen sonuçlar, geliştirilen CNN modelinin yaş tahmini, cinsiyet sınıflandırması ve duygu analizi konularında başarılı olduğunu göstermektedir. UTK Face veri setindeki geniş demografik çeşitlilik ve Fer2013 veri setindeki farklı duygu ifadeleri, modelin çeşitli senaryolarda ve koşullarda iyi performans sergilediğini ortaya koymaktadır.

Yaş tahmini konusunda, modelin verileri doğru bir şekilde sınıflandırdığı ve gerçek yaşa yakın sonuçlar ürettiği gözlemlenmiştir. Cinsiyet sınıflandırması için ise modelin yüksek doğruluk oranlarına ulaştığı ve cinsiyeti doğru bir şekilde belirlediği görülmüştür. Duygu analizi alanında, modelin Fer2013 veri setindeki farklı duygu ifadeleri başarıyla tanımladığı ve duygu durumu doğru bir şekilde tahmin ettiği gözlemlenmiştir. Bu da modelin duygusal analiz konusunda etkili bir araç olduğunu göstermektedir.

Sonuç olarak, derin öğrenme ve CNN modeli kullanılarak gerçekleştirilen yaş, cinsiyet ve duygu analizi çalışması başarılı sonuçlar sunmaktadır. Bu çalışma, görüntü üzerinden kişisel özelliklerin ve duygu durumun analiz edilebilmesi için etkili bir yöntem sağlamaktadır. Elde edilen sonuçlar, derin öğrenme ve CNN'nin yüz analizi alanında güçlü bir potansiyele sahip olduğunu göstermektedir.

### 5.2. Öneriler

Çalışmanın sonuçlarına dayanarak, yaş, cinsiyet ve duygu analizi üzerine yapılan araştırmaları geliştirmek ve daha doğru sonuçlar elde etmek için aşağıdaki öneriler sunulmaktadır:

1. Veri Kümesinin Genişletilmesi: UTK Face veri kümesi ve Fer2013 veri kümesi gibi daha büyük ve çeşitlilik açısından zengin veri setlerinin kullanılması, algoritmaların genelleştirilebilirliğini ve performansını artırabilir. Bu, farklı yaş grupları, ırklar, etnik kökenler ve coğrafi bölgelerden daha fazla örneğin dahil edilmesini içerir.
2. Duygu Analizi Algoritmalarının İyileştirilmesi: Duygu analizi sonuçlarının hassaslığını artırmak için daha gelişmiş analiz mekanizmalarının kullanılması

önerilmektedir. Derin öğrenme teknikleri ve duygusal içeriği daha iyi anlayan modellerin geliştirilmesi, duygu analizinde daha doğru sonuçlar elde etmeye yardımcı olabilir.

3. Veri Ön İşleme Yöntemlerinin İyileştirilmesi: Veri ön işleme aşamasında daha etkili ve doğru yöntemlerin kullanılması, yüz tanıma algoritmalarının performansını artırabilir. Gürültü azaltma, yüz özniteliklerinin daha iyi çıkarılması ve veri dengesizliklerinin giderilmesi gibi önemli adımların gözden geçirilmesi önerilmektedir.
4. Daha Büyük Ölçekli Veri Setlerinin Kullanılması: Daha büyük ölçekli veri setlerinin kullanılması, yüz tanıma algoritmalarının genelleştirilebilirliğini ve güvenilirliğini artırabilir. Bu, gerçek dünya senaryolarını daha iyi yansıtan veri setlerinin oluşturulması ve kullanılması anlamına gelir.
5. Farklı Faktörlerin Analiz Edilmesi: Yaş, cinsiyet ve duygu analizine ek olarak, farklı faktörlerin (örneğin, ırk, etnik köken, duygu yoğunluğu) analize dahil edilmesi, daha kapsamlı bir inceleme sağlayabilir. Bu, yüz tanıma algoritmalarının daha fazla bağımsız değişkeni dikkate almasını ve sonuçların daha ayrıntılı ve farklı perspektiflerden değerlendirilmesini sağlar.
6. Daha Gelişmiş Öğrenme Algoritmalarının Kullanılması: Yüz tanıma tekniklerinde daha gelişmiş öğrenme algoritmalarının kullanılması, daha yüksek doğruluk ve performans elde etmek için önemlidir. Örneğin, derin öğrenme algoritmaları, daha karmaşık ve derin ağ yapılarıyla yüz tanıma problemlerine daha iyi uyum sağlayabilir.
7. Model Optimizasyonu ve Hızlandırma: Yüz tanıma algoritmalarının gerçek zamanlı uygulamalarda daha hızlı çalışması için model optimizasyonu ve hızlandırma tekniklerinin kullanılması önerilmektedir. Bu, model boyutunu azaltmak, hesaplama optimizasyonu yapmak ve donanım hızlandırma teknolojilerinden yararlanmak gibi adımları içerir.
8. Performans Metriklerinin Çeşitlendirilmesi: Yüz tanıma algoritmalarının performansını değerlendirmek için farklı metriklerin kullanılması önemlidir. Sadece doğruluk oranı değil, aynı zamanda hassasiyet, özgüllük, yanlış pozitif oranı gibi farklı metriklerin analiz edilmesi sonuçların daha kapsamlı bir şekilde değerlendirilmesine yardımcı olabilir.
9. Etik ve Gizlilik Konularının Dikkate Alınması: Yüz tanıma teknolojilerinin kullanımıyla ilgili etik ve gizlilik konularının dikkate alınması önemlidir.

Çalışmaların bu konulara odaklanması ve geliştirilen algoritmaların adalet, güvenlik ve özel hayatı koruma ilkelerine uygun olduğundan emin olunması gerekmektedir.

Sonuç olarak, bu araştırma yaş, cinsiyet ve duygu analizi üzerine yapılan çalışmalara katkı sağlamıştır. Önerilen iyileştirmelerin dikkate alınması, yüz tanıma tekniklerinin daha doğru, genelleştirilebilir ve güvenilir hale gelmesine yardımcı olacaktır. Ayrıca, etik ve gizlilik ilkelerine uygunluğun gözetilmesi, teknolojinin toplumda kabul edilebilir bir şekilde kullanılmasını sağlayacaktır. Gelecekteki araştırmaların bu önerilere odaklanarak alanın ilerlemesine katkıda bulunmasını umuyoruz.

## 6. KAYNAKLAR

- [1] <https://azure.microsoft.com> (Erişim Tarihi:10.11.2022)
- [2] Samtaş, G. & Gülesin, M., (2011), Sayısal Görüntü İşleme ve Farklı Alanlardaki Uygulamaları, *Electronic Journal of Vocational Colleges*, 85-97.
- [3] Şeker, A., Diri, B. & Balık, H., (2017), Derin Öğrenme Yöntemleri ve Uygulamaları Hakkında Bir İnceleme, *Gazi Mühendislik Bilimleri Dergisi*, 3(3): 47-64.
- [4] Kaya, U., Yılmaz, A. & Dikmen, Y., (2019), Sağlık Alanında Kullanılan Derin Öğrenme Yöntemleri, *Avrupa Bilim ve Teknoloji Dergisi*, 792-808.
- [5] Güler, T., (2022), Gerçek Zamanlı Duygu Durumu Analizi: Derin Öğrenme Tabanlı Akıllı Sistem Tasarımı, Yüksek Lisans Tezi, Bartın Üniversitesi, Bartın.
- [6] Eldem, A., Eldem, H. & Palalı, A., (2017), Görüntü İşleme Teknikleriyle Yüz Algılama Sistemi Geliştirme, 6 (2), 44-48.
- [7] Ergün, G., Güney, S. & Ergün, T., (2021), Köpeklerdeki Uzun Kemiklerin Evrişimli Sinir Ağları Kullanılarak Sınıflandırılması, 33 (1), 125-132.
- [8] Türkoğlu, M., Hanbay, K., Saraç, I. & Hanbay, D., (2020), Derin Evrişimli Sinir Ağı Kullanılarak Kayısı Hastalıklarının Sınıflandırılması, 9 (1), 334-345.
- [9] Padilla, R., Costa, d M. G. F., (2012), Evaluation of Haar Cascade Classifiers Designed for Face Detection, 6-4.
- [10] <http://opencv.org/> (Erişim Tarihi: 24.12.2022)
- [11] Karakurt, M., & İşeri, İ., (2022), Patoloji Görüntülerinin Derin Öğrenme Yöntemleri ile Sınıflandırılması, 192-206.
- [12] Ayvaz, U. & Gürüler, H., (2017), Bilgisayar Kullanıcılarına Yönelik Duygusal İfade Tespiti, 10(2), 231-239.
- [13] Gündüz, G., & Cedimoğlu, İ., (2019), Derin Öğrenme Algoritmalarını Kullanarak Görüntüden Cinsiyet Tahmini, 9-17.
- [14] Kılıç, Ö., Aydemir, M. & Özdemir, P., (2022), Uçak Görüntülerinin Sınıflandırılmasında Farklı Yapay Zekâ Algoritmalarının Performansı, 5 (2), 84-88.
- [15] Çapşek, M. & Karacı. A., (2022), Derin Öğrenme ve Görüntü İşleme Yöntemlerini Kullanarak Yüz ve Göz Hareketleri ile Bilgisayar Kontrolü, 4(9), 1170-1177.
- [16] Tarı, M., (2020), Görüntü İşleme Teknikleri ile Enjektör Üretiminde Kalite Kontrolü, Yüksek Lisans Tezi, Konya Teknik Üniversitesi, Konya.



- [17] Kaplan, A., (2018), Gerçek ve Yarı Gerçek Zamanlı Yüz Tespit Etme, Yüksek Lisans Tezi, Fırat Üniversitesi, Elazığ, 21-22.
- [18] Vural, R., Sert, M., Karaköse, B., (2018), Gerçek Zamanlı Sürücü Yorgunluk Tespit Sistemi, 3: 249-259.
- [19] Mazen, F., Mazen A., Nashat A., Seoud A., (2021), Real Time Face Expression Recognition along with Balanced FER2013 Dataset using CycleGAN, 12-6.
- [20] Söylemez, Ö. & Ergen, B., (2020), Farklı Evrişimli Sinir Ağı Mimarilerinin Yüz İfade Analizi Alanındaki Başarımlarının İncelenmesi, 11(1),123-133.
- [21] Amal, V. S. & Deepa, G., (2021), Real-Time Emotion Recognition from Facial Expressions Using Convolutional Neural Network with Fer2013 Dataset, Smart Innovation, Systems and Technologies, 541–551.
- [22] Anonymous authors., (2021), Maximum Categorical Cross Entropy (Mcce): A Noise-Robust Alternative Loss Function To Mitigate Racial Bias In Convolutional Neural Networks (Cnns) By Reducing Overfitting, Under review as a conference paper at ICLR 2021.
- [23] <https://susanqq.github.io/UTKFace/> (Erişim Tarihi: 18.05.2023)
- [24] Ayan, Ş., (2018), Yüz Görüntülerinden Kırışıklık Tespiti ve Sınıflandırılmasıyla Yaş Tahmini Algoritması Geliştirilmesi, Yüksek Lisans Tezi, Tobb Ekonomi ve Teknoloji Üniversitesi Fen Bilimleri Enstitüsü, Ankara.

## ÖZGEÇMİŞ

### KİŞİSEL BİLGİLER

**Adı Soyadı** : Fadime COŞKUNER  
**Uyruğu** : TC  
**Doğum Yeri ve Tarihi** : Karaman, 15.01.2001  
**Telefon** : 0531 981 78 48  
**Faks** :  
**e-mail** : fadimeecoskuner@gmail.com

### EĞİTİM

Derece	Adı, İlçe, İl	Bitirme Yılı
Lise	: Cemil Keleşoğlu Anadolu Lisesi, Karatay Konya	2019
Üniversite	: Necmettin Erbakan Üniversitesi, Seydişehir Konya	

### İŞ DENEYİMLERİ

Yıl	Kurum	Görevi
2023	Armiya Yazılım	Web Tasarım

## ÖZGEÇMİŞ

### KİŞİSEL BİLGİLER

**Adı Soyadı** : Meryem ŞAHİN  
**Uyruğu** : TC  
**Doğum Yeri ve Tarihi** : UŞAK / 16.03.2000  
**Telefon** : 0507 836 91 32  
**Faks** :  
**e-mail** : meryemshins@gmail.com

### EĞİTİM

Derece	Adı, İlçe, İl	Bitirme Yılı
Lise	: Ayşe Ana Mesleki ve Teknik Anadolu Lisesi, Merkez, Uşak	2018
Üniversite	: Necmettin Erbakan Üniversitesi, Seydişehir. Konya	

### İŞ DENEYİMLERİ

Yıl	Kurum	Görevi
2023	Balta Floorcovering Yer Döşemeleri San.	IT Stajyer